

ArbolesDeDecision

Cristopher Barrios, Carlos Daniel Estrada

2023-03-10

librerias

```
library(rpart)
library(rpart.plot)
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

```
library(fpc)
library(cluster)
library("ggpubr")
```

```
## Loading required package: ggplot2
```

```
library(mclust)
```

```
## Package 'mclust' version 6.0.0
## Type 'citation("mclust")' for citing this R package in publications.
```

```
library(caret)
```

```
## Loading required package: lattice
```

```
library(tree)
library(randomForest)
```

```
## randomForest 4.7-1.1
```

```
## Type rfNews() to see new features/changes/bug fixes.
```

```

##
## Attaching package: 'randomForest'

## The following object is masked from 'package:ggplot2':
##
##     margin

## The following object is masked from 'package:dplyr':
##
##     combine

library(plyr)

## -----

## You have loaded plyr after dplyr - this is likely to cause problems.
## If you need functions from both plyr and dplyr, please load plyr first, then dplyr:
## library(plyr); library(dplyr)

## -----

##
## Attaching package: 'plyr'

## The following object is masked from 'package:ggpubr':
##
##     mutate

## The following objects are masked from 'package:dplyr':
##
##     arrange, count, desc, failwith, id, mutate, rename, summarise,
##     summarize

library("stats")
library("datasets")
library("prediction")
library(tidyverse)

## -- Attaching packages ----- tidyverse 1.3.2
## --

## v tibble 3.1.8      v purrr 1.0.1
## v tidyr 1.3.0       v stringr 1.5.0
## v readr 2.1.3       v forcats 1.0.0
## -- Conflicts ----- tidyverse_conflicts() --
## x plyr::arrange()      masks dplyr::arrange()
## x randomForest::combine() masks dplyr::combine()
## x purrr::compact()     masks plyr::compact()
## x plyr::count()        masks dplyr::count()
## x plyr::failwith()     masks dplyr::failwith()

```

```
## x dplyr::filter()      masks stats::filter()
## x plyr::id()           masks dplyr::id()
## x dplyr::lag()         masks stats::lag()
## x purrr::lift()        masks caret::lift()
## x purrr::map()         masks mclust::map()
## x randomForest::margin() masks ggplot2::margin()
## x plyr::mutate()        masks ggpubr::mutate(), dplyr::mutate()
## x plyr::rename()        masks dplyr::rename()
## x plyr::summarise()     masks dplyr::summarise()
## x plyr::summarize()     masks dplyr::summarize()
```

1. Use los mismos conjuntos de entrenamiento y prueba que usó para los árboles de decisión en la hoja de trabajo anterior.

```
datos = read.csv("./train.csv")
test<- read.csv("./test.csv", stringsAsFactors = FALSE)
```

Lo Realizado anteriormente:

Inciso 4

```
set_entrenamiento <- sample_frac(datos, .7)
set_prueba <- setdiff(datos, set_entrenamiento)
```

```
drop <- c("LotFrontage", "Alley", "MasVnrType", "MasVnrArea", "BsmtQual", "BsmtCond", "BsmtExposure", "
set_entrenamiento <- set_entrenamiento[, !(names(set_entrenamiento) %in% drop)]
set_prueba <- set_prueba[, !(names(set_prueba) %in% drop)]
```

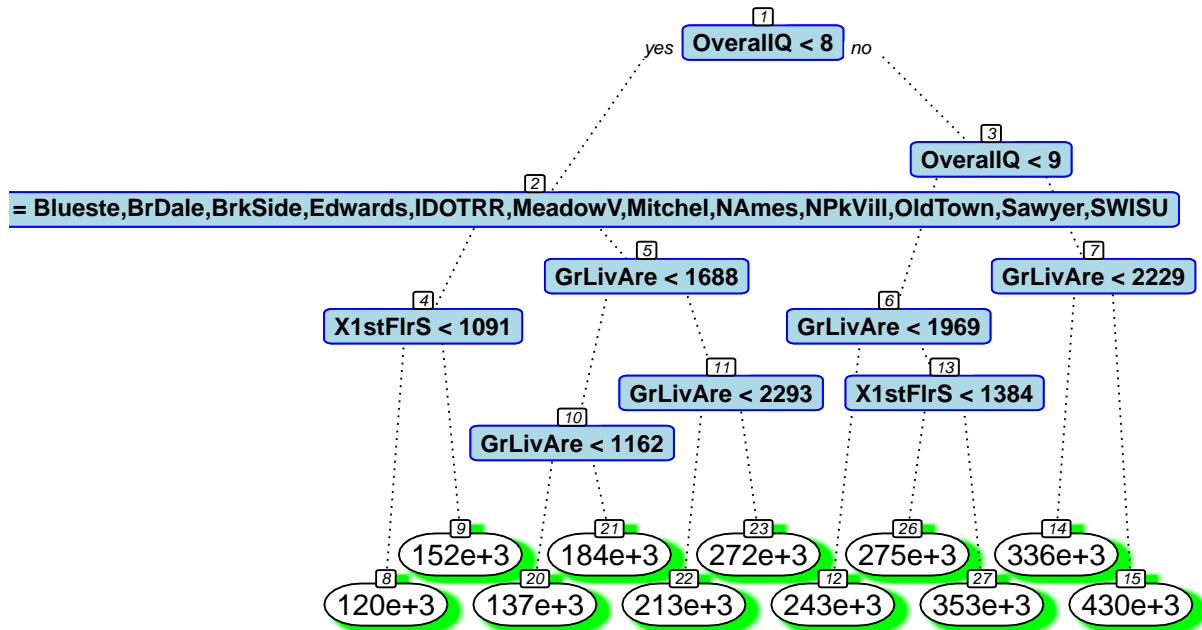
2. Elabore un árbol de regresión para predecir el precio de las casas usando todas las variables.

```
arbol_3 <- rpart(SalePrice ~ ., data = set_entrenamiento)
```

```
prp(arbol_3, main="Arbol de Regresion", nn=TRUE, fallen.leaves = TRUE, shadow.col = "green", branch.lty
```

```
## cex 0.948 xlim c(0, 1) ylim c(0, 1)
```

Arbol de Regresion



–modelo del arbol de decision

```
#arbolModelo1 <- rpart(SalePrice~.,set_prueba,method = "class")
#rpart.plot(arbolModelo1)
```

–graficar arbol

3. Úselo para predecir y analice el resultado. ¿Qué tal lo hizo?

```
predicciones <- predict(arbol_3, data = set_prueba)
mse <- mean((predicciones - set_prueba$SalePrice)^2)
```

```
## Warning in predicciones - set_prueba$SalePrice: longitud de objeto mayor no es
## múltiplo de la longitud de uno menor
```

```
mse
```

```
## [1] 11576704151
```

- ```
datos$clasificacion <- ifelse(datos$SalePrice > 290000, "Caras", ifelse(datos$SalePrice > 170000, "Intemedias", "Economicas"))
table(datos$clasificacion)

##
Caras Economicas Intemedias
121 792 547

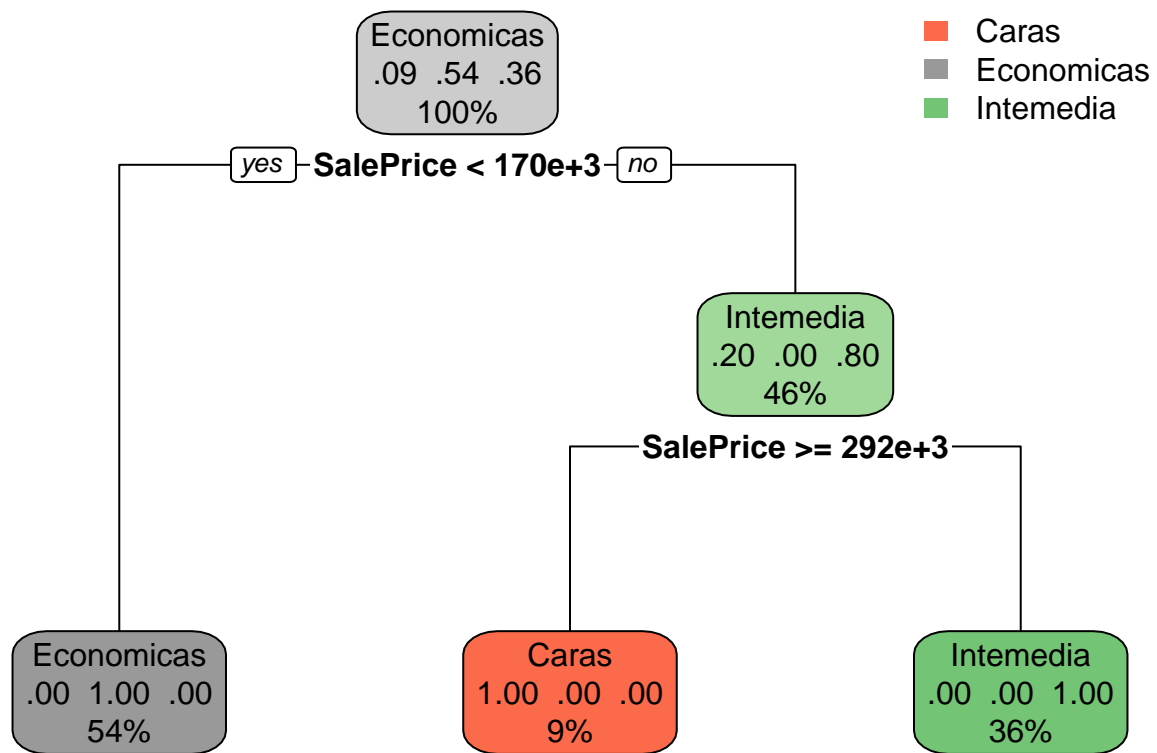
set_entrenamiento <- sample_frac(datos, .7)
set_prueba <- setdiff(datos, set_entrenamiento)

drop <- c("LotFrontage", "Alley", "MasVnrType", "MasVnrArea", "BsmtQual", "BsmtCond", "BsmtExposure", "BsmtFinType1", "BsmtFinType2", "MasVnrType1", "MasVnrType2", "MasVnrType3", "MasVnrType4", "MasVnrType5", "MasVnrType6", "MasVnrType7", "MasVnrType8", "MasVnrType9", "MasVnrType10", "MasVnrType11", "MasVnrType12", "MasVnrType13", "MasVnrType14", "MasVnrType15", "MasVnrType16", "MasVnrType17", "MasVnrType18", "MasVnrType19", "MasVnrType20", "MasVnrType21", "MasVnrType22", "MasVnrType23", "MasVnrType24", "MasVnrType25", "MasVnrType26", "MasVnrType27", "MasVnrType28", "MasVnrType29", "MasVnrType30", "MasVnrType31", "MasVnrType32", "MasVnrType33", "MasVnrType34", "MasVnrType35", "MasVnrType36", "MasVnrType37", "MasVnrType38", "MasVnrType39", "MasVnrType40", "MasVnrType41", "MasVnrType42", "MasVnrType43", "MasVnrType44", "MasVnrType45", "MasVnrType46", "MasVnrType47", "MasVnrType48", "MasVnrType49", "MasVnrType50", "MasVnrType51", "MasVnrType52", "MasVnrType53", "MasVnrType54", "MasVnrType55", "MasVnrType56", "MasVnrType57", "MasVnrType58", "MasVnrType59", "MasVnrType60", "MasVnrType61", "MasVnrType62", "MasVnrType63", "MasVnrType64", "MasVnrType65", "MasVnrType66", "MasVnrType67", "MasVnrType68", "MasVnrType69", "MasVnrType70", "MasVnrType71", "MasVnrType72", "MasVnrType73", "MasVnrType74", "MasVnrType75", "MasVnrType76", "MasVnrType77", "MasVnrType78", "MasVnrType79", "MasVnrType80", "MasVnrType81", "MasVnrType82", "MasVnrType83", "MasVnrType84", "MasVnrType85", "MasVnrType86", "MasVnrType87", "MasVnrType88", "MasVnrType89", "MasVnrType90", "MasVnrType91", "MasVnrType92", "MasVnrType93", "MasVnrType94", "MasVnrType95", "MasVnrType96", "MasVnrType97", "MasVnrType98", "MasVnrType99", "MasVnrType100")
set_entrenamiento <- set_entrenamiento[, !(names(set_entrenamiento) %in% drop)]
set_prueba <- set_prueba[, !(names(set_prueba) %in% drop)]
```

- ```
arbol_4 <- rpart(formula = clasificacion ~ ., data = set_entrenamiento)
arbol_4

## n= 1022
##
## node), split, n, loss, yval, (yprob)
##      * denotes terminal node
##
## 1) root 1022 466 Economicas (0.09197652 0.54403131 0.36399217)
##    2) SalePrice< 170500 556    0 Economicas (0.00000000 1.00000000 0.00000000) *
##    3) SalePrice>=170500 466   94 Intemedia (0.20171674 0.00000000 0.79828326)
##      6) SalePrice>=291538.5 94    0 Caras (1.00000000 0.00000000 0.00000000) *
##      7) SalePrice< 291538.5 372    0 Intemedia (0.00000000 0.00000000 1.00000000) *

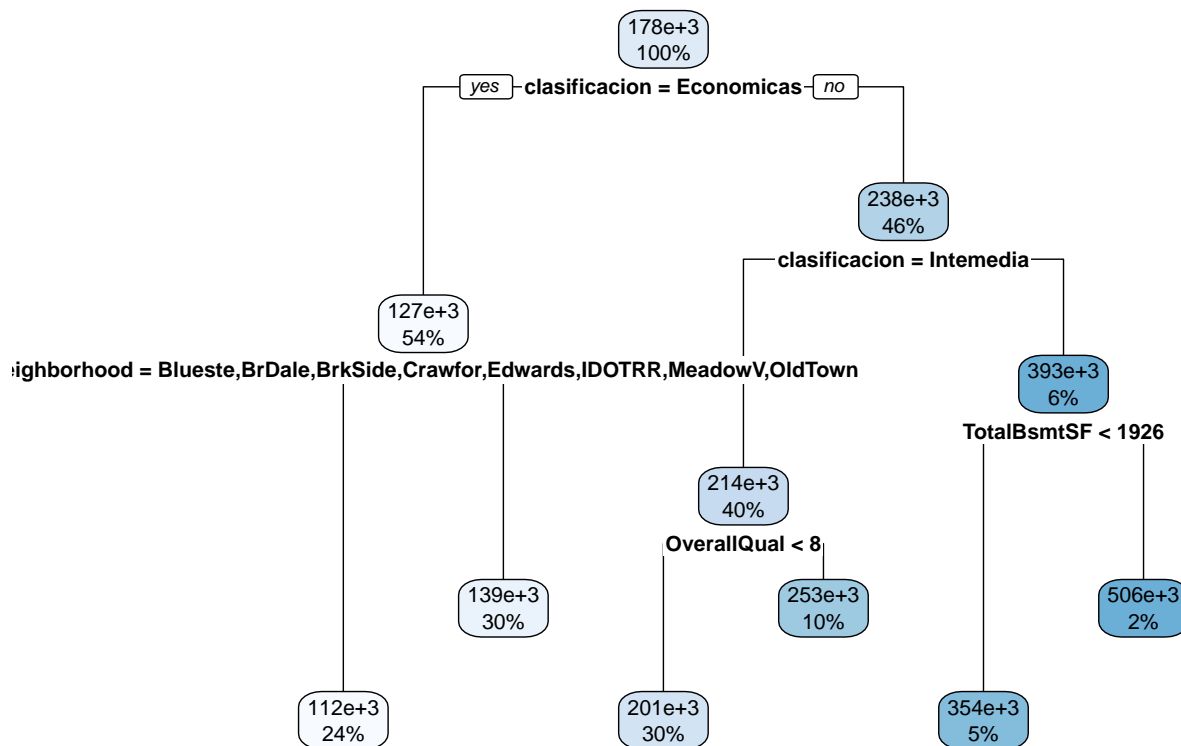
rpart.plot(arbol_4)
```



8. Utilice el modelo con el conjunto de prueba y determine la eficiencia del algoritmo para clasificar.

```
set_prueba <- set_prueba[, !(names(set_prueba) %in% drop)]
arbol_5 <- rpart(SalePrice ~ ., data = set_prueba)
```

```
rpart.plot(arbol_5)
```



```

predicciones <- predict(arbol_5, newdata = set_prueba)
error <- abs(predicciones - set_prueba$SalePrice)
eficiencia <- 1 - mean(error / set_prueba$SalePrice)
eficiencia

```

```
## [1] 0.8588787
```

9. Haga un análisis de la eficiencia del algoritmo usando una matriz de confusión para el árbol de clasificación. Tenga en cuenta la efectividad, donde el algoritmo se equivocó más, donde se equivocó menos y la importancia que tienen los errores.

10. Entrene un modelo usando validación cruzada, prediga con él. ¿le fue mejor que al modelo anterior?

11. Haga al menos, 3 modelos más cambiando la profundidad del árbol. ¿Cuál funcionó mejor?

12. Repite los análisis usando random forest como algoritmo de predicción, explique sus resultados comparando ambos algoritmos.

```

#set.seed(123)
#modelo <- randomForest(SalePrice ~ ., data = set_entrenamiento)
#prediccion_2 <- predict(modelo, set_prueba)
#mc <- table(prediccion_2, set_prueba$SalePrice)

```